

POSTECH DTAT

Tech Challenge — Fase 2

Classificação de Qualidade de Vinhos

com Machine Learning

Relatório Técnico

Grupo

Efraim Oliveira

Érica Tarsis

Ricardo Moraes

Rodrigo Bernardino

Thiago Galvão

São Paulo · 2026

Sumário

Sumário	2
Índice de Figuras	3
Índice de Tabelas	3
Resumo Executivo	4
Artefatos e Links do Projeto	4
1. Compreensão do Problema	5
1.1 Contexto e motivação	5
1.2 Definição da variável-alvo e estratégia de binarização	5
1.3 Visão geral da metodologia	6
2. Análise Exploratória de Dados (EDA)	7
2.1 Governança e qualidade dos dados	7
2.2 Distribuição das notas de qualidade	7
2.3 Balanceamento das classes e a solução adotada	8
2.4 Distribuição das variáveis	8
2.5 Detecção de outliers (método IQR)	10
2.6 Correlações com olhar de negócio	11
2.7 Poder discriminante por classe	13
2.8 Multicolinearidade (VIF)	13
3. Pré-Processamento de Dados	14
3.1 Tratamentos aplicados	14
3.2 Engenharia de variáveis (criada, testada e descartada)	14
3.3 Interações entre variáveis	14
3.4 Robustez a distribuições assimétricas (teste logarítmico)	14
4. Desenvolvimento de Modelos	15
4.1 Algoritmos testados experimentalmente	15
4.2 Tratamento do desbalanceamento (Parte I)	15
4.3 Otimização de hiperparâmetros	15
5. Avaliação — Parte I (corte ≥ 7 , desbalanceado)	16
5.1 Resultados sem correção de desbalanceamento	16
5.2 Resultados com ajuste de peso das classes	17
6. Avaliação — Parte II (corte ≥ 6 , equilibrado)	18
6.1 Comparação entre os modelos	18
6.2 O trade-off entre os dois erros e o impacto no negócio	19
6.3 Capacidade de separação (curva ROC)	19
6.4 Significância estatística e robustez das diferenças	20
7. Interpretação dos Resultados	22
7.1 Importância das variáveis pela Random Forest	22
7.2 Análise SHAP	22
7.3 Implicações para o processo produtivo	23
7.4 Importância por permutação	24
8. Riscos, Limitações e Governança	25
8.1 Limitações metodológicas	25
8.2 Reprodutibilidade	25
9. Conclusões e Recomendações	26
10. Recomendação de implantação	26
11. Referências	27

Índice de Figuras

Figura 1 – Fluxograma da metodologia, da base original à recomendação.	6
Figura 2 – Distribuição das notas de qualidade na base limpa ($n = 1.018$).	7
Figura 3 – Balanceamento das classes nos dois limiares.	8
Figura 4 - Histogramas das onze variáveis físico-químicas.	9
Figura 5 - Boxplots das três variáveis com maior incidência de outliers (mantidos na base).	10
Figura 6 - Correlação de Pearson de cada variável com a nota de qualidade.	12
Figura 7 - Mapa de calor das correlações entre todas as variáveis.	12
Figura 8 - Distribuição das variáveis-chave por classe (corte ≥ 6).	13
Figura 9 - F1-Score por modelo na Parte I, sem correção (destaque para o melhor).	16
Figura 10 - F1-Score por modelo na Parte I, com ajuste de peso das classes.	17
Figura 11 - F1-Score por modelo na Parte II (conjunto de teste).	18
Figura 12 - Matrizes de confusão no conjunto de teste (corte ≥ 6): recomendado $\times$ melhor F1.	19
Figura 13 - Curvas ROC dos sete modelos (corte ≥ 6), com as respectivas áreas (AUC).	20
Figura 14 - Curvas Precision-Recall (corte ≥ 6), com Average Precision (AP).	21

Índice de Tabelas

Tabela 1 – Os dois limiares de binarização analisados.	5
Tabela 2 - Estatística descritiva das variáveis (base limpa, $n = 1.018$).	9
Tabela 3 - Contagem de outliers por variável (método IQR), sobre a base limpa.	10
Tabela 4 - Fator de Inflação de Variância por variável ($> 5 =$ atenção).	13
Tabela 5 - Efeito da variável <code>so2_ratio</code> no F1 (validação cruzada, 5 dobras).	14
Tabela 6 - Efeito das interações no F1 (validação cruzada, 5 dobras).	14
Tabela 7 - Regressão Logística com e sem transformação logarítmica das variáveis assimétricas.	14
Tabela 8 - Melhores configurações encontradas pela busca em grade (GridSearchCV).	15
Tabela 9 - Ganho da otimização de hiperparâmetros (F1 em validação cruzada).	15
Tabela 10 - Parte I (corte ≥ 7), sem correção de desbalanceamento. Ordenado por F1-Score.	16
Tabela 11 - Parte I (corte ≥ 7), com <code>class_weight = 'balanced'</code> . Ordenado por F1-Score.	17
Tabela 12 - Parte II (corte ≥ 6): desempenho no conjunto de teste. Ordenado por F1-Score.	18
Tabela 13 - Estabilidade dos modelos: F1 médio e desvio em validação cruzada (5 dobras).	19
Tabela 14 - F1 de teste e intervalo de confiança de 95% (bootstrap, 3.000 reamostragens).	21
Tabela 15 - Importância das variáveis segundo a Random Forest.	22
Tabela 16 - Resumo SHAP: impacto de cada variável na previsão da classe “Alta qualidade”.	23
Tabela 17 - Dependência SHAP do teor alcoólico e dos sulfatos (corte ≥ 6).	24
Tabela 18 - Importância por permutação (queda média de F1), gráfico revisado.	24

Resumo Executivo

Este relatório apresenta a metodologia, os experimentos e as conclusões de um projeto de classificação binária da qualidade de vinhos tintos, desenvolvido sobre a base pública WineQT (Kaggle). O objetivo é distinguir vinhos de alta qualidade dos de baixa/média qualidade usando exclusivamente variáveis físico-químicas mensuráveis durante a produção — apoiando a avaliação sensorial humana, que é subjetiva, lenta e cara.

Sob um único protocolo — mesma divisão treino/teste (80/20 estratificada), mesma validação cruzada (estratificada, cinco dobras) e mesma semente aleatória, foram efetivamente treinados e comparados sete algoritmos. No cenário principal (corte de qualidade ≥ 6), os melhores modelos alcançaram F1-Score entre **0,76 e 0,79** no conjunto de teste. Em validação cruzada, a Random Forest obteve o melhor F1 médio (**0,762**) e o menor desvio (**$\pm 0,015$**), confirmando-se como o modelo **mais robusto e mais estável**.

Um achado metodológico relevante: aplicados testes de significância (McNemar, comparação pareada por dobras e intervalos de confiança por bootstrap), as diferenças entre os modelos do topo **não são estatisticamente significativas**. Por isso, a escolha do modelo de produção é feita por critérios operacionais — recomenda-se a **Random Forest otimizada** (melhor desempenho em validação cruzada, robustez a outliers e interpretabilidade), com a Regressão Logística como modelo-companheiro transparente.

Três variáveis físico-químicas destacaram-se como preditores dominantes, confirmadas por três métodos independentes de interpretabilidade: o **teor alcoólico** (influência positiva), os **sulfatos** (positiva) e a **acidez volátil** (negativa). Cada uma tem interpretação direta no processo produtivo, convertendo o modelo estatístico em recomendações concretas de gestão para a vinícola.

Artefatos e Links do Projeto

Os artefatos avaliáveis deste projeto estão nos endereços abaixo. Substituir os marcadores pelos links definitivos do grupo antes da entrega e garantir que o repositório esteja público e o vídeo acessível (itens eliminatórios).

- Repositório GitHub: <https://github.com/lgmricardo/Techchallenge2-G12>
- Vídeo executivo (YouTube): <https://youtu.be/<id-do-video>>
- Apresentação executiva: disponível na pasta /apresentacao do repositório (PPT/PDF)

1. Compreensão do Problema

1.1 Contexto e motivação

A qualidade de um vinho é tradicionalmente avaliada por especialistas, em análises sensoriais que consideram aroma, sabor, acidez e equilíbrio. Esse processo é, por natureza, subjetivo, varia de pessoa para pessoa e consome tempo. Como hoje é possível medir com precisão e baixo custo diversas propriedades físico-químicas durante a produção, surge a oportunidade de construir modelos preditivos que antecipem a classificação de qualidade a partir de dados objetivos.

Para o negócio há dois ganhos concretos: (1) reduzir o tempo e o custo do controle de qualidade, que deixa de depender exclusivamente de degustadores; e (2) separar antecipadamente os lotes de alta qualidade, direcionando-os a uma precificação premium e protegendo a margem de lucro.

1.2 Definição da variável-alvo e estratégia de binarização

A base traz uma nota de qualidade de 3 a 8. Para transformar o problema em classificação binária (alta × baixa/média) é preciso escolher um ponto de corte — escolha que determina o equilíbrio entre as classes e, por consequência, a dificuldade do problema. Por isso os dois limiares foram analisados de forma comparativa, e não adotados por convenção.

Limiar	Classe “Alta”	Situação	Papel no estudo
≥ 7 (sugerido no enunciado)	~13%	Desbalanceado ($\approx 6,4 : 1$)	Parte I — demonstra a armadilha da acurácia
≥ 6 (estratégia principal)	~54%	Equilibrado ($\approx 54/46$)	Parte II — decisão guiada pelos dados

Tabela 1 – Os dois limiares de binarização analisados.

Trata-se de uma **decisão de pré-processamento** justificada pelos próprios dados (Seção 2.2): as notas 6 e superiores concentram a maior parte das amostras avaliadas acima da média, e o equilíbrio resultante elimina o viés de classe sem reamostragem externa. **Não é calibragem para inflar acurácia** — apenas calibrar para atingir uma métrica seria superajuste.

Para leigos: escolher o corte é como definir a “nota de aprovação”. Aprovar apenas quem tirou ≥ 7 deixa pouquíssimos aprovados (turma desbalanceada); a fronteira ≥ 6 separa melhor o “mediano” do “bom”.

1.3 Visão geral da metodologia

O fluxograma a seguir resume o fluxo completo do projeto, das etapas de preparação à recomendação final; cada bloco é detalhado nas seções seguintes.



Figura 1 – Fluxograma da metodologia, da base original à recomendação.

2. Análise Exploratória de Dados (EDA)

2.1 Governança e qualidade dos dados

Seguindo o princípio de “preparar-se para o pior” (Lei de Murphy), a base foi auditada antes de qualquer análise. A base original tinha **1.143 amostras** e 13 colunas, sem nenhum valor nulo. Foram identificados **125 registros idênticos** — mesmas onze medições físico-químicas e a mesma nota — reduzidos a uma única ocorrência cada, restando **1.018 amostras**.

Ponto metodológico: a verificação de duplicidade ignorou deliberadamente a coluna de identificação (Id). Esse campo é apenas um contador sequencial; se fosse considerado, nenhuma linha seria vista como duplicada e as repetições reais passariam despercebidas. Todas as estatísticas e modelos a seguir foram calculados exclusivamente sobre a base limpa de 1.018 amostras.

2.2 Distribuição das notas de qualidade

A distribuição revela forte concentração nos valores centrais: as notas 5 e 6 somam **842 amostras (≈ 82,7%)**. Os extremos são raros (nota 3 em 6 amostras; nota 4 em 33; nota 8 em 15). Esse padrão é típico de avaliações humanas, que evitam extremos. Na prática, o desafio real não é separar um vinho péssimo de um excelente, mas o “mediano” do “bom” — fronteira sutil que limita o teto de desempenho.




Figura 2 – Distribuição das notas de qualidade na base limpa (n = 1.018).

2.3 Balanceamento das classes e a solução adotada

Com o corte ≥ 7 , a base fica fortemente desequilibrada (137 de alta $\times$ 881 de baixa/média). Nesse cenário, um modelo ingênuo que classificasse todo vinho como “baixa/média” acertaria **86,5%** das vezes — sem nunca identificar um único vinho de alta qualidade. É a **armadilha da acurácia**. A solução tem dois níveis: na definição do problema, o corte ≥ 6 equilibra as classes na origem ($\approx 54/46$); no algoritmo, para o corte ≥ 7 , aplica-se `class_weight = 'balanced'` (Seção 4.2).

Balanceamento das classes por limiar de binarização




Figura 3 – Balanceamento das classes nos dois limiares.

2.4 Distribuição das variáveis

O teor alcoólico é quase simétrico; a acidez volátil, os cloretos e o açúcar residual são assimétricos à direita (caudas longas $\rightarrow$ indício de outliers); o ácido cítrico sugere leve bimodalidade. Modelos lineares (Regressão Logística) são, em princípio, mais sensíveis a distribuições assimétricas que os de árvore — ponto **testado empiricamente na Seção 3.4**, onde mostramos que a assimetria não é o gargalo neste problema.




Figura 4 - Histogramas das onze variáveis físico-químicas.

A tabela a seguir consolida as estatísticas descritivas das onze variáveis físico-químicas e da nota de qualidade, sobre a base limpa ($n = 1.018$), oferecendo a visão quantitativa que complementa os histogramas.

Variável	Média	Mediana	Desvio-padrão	Mínimo	Máximo
Acidez fixa	8,289	7,9	1,741	4,6	15,9
Acidez volátil	0,534	0,52	0,183	0,12	1,58
Ácido cítrico	0,269	0,25	0,196	0	1
Açúcar residual	2,524	2,2	1,315	0,9	15,5
Cloretos	0,087	0,079	0,049	0,012	0,611
Dióxido de enxofre livre	15,649	13	10,177	1	68
Dióxido de enxofre total	46,326	38	33,124	6	289
Densidade	0,997	0,997	0,002	0,99	1,004
pH	3,312	3,31	0,158	2,74	4,01
Sulfatos	0,657	0,62	0,168	0,33	2
Teor alcoólico	10,452	10,2	1,095	8,4	14,9
Qualidade	5,641	6	0,812	3	8

Tabela 2 - Estatística descritiva das variáveis (base limpa, $n = 1.018$).

2.5 Detecção de outliers (método IQR)

Aplicou-se o método do intervalo interquartil (IQR): é outlier o valor fora de $[Q1 - 1,5 \cdot IQR ; Q3 + 1,5 \cdot IQR]$. A decisão de governança, documentada, foi manter esses valores: (1) todos os extremos são fisicamente plausíveis para vinhos tintos; (2) os modelos de árvore são robustos a outliers; (3) a padronização reduz seu impacto na Regressão Logística. Remover outliers reais sem justificativa física descartaria informação legítima.

Variável	Outliers (n)	% da base
Açúcar residual	95	9,3%
Cloretos	71	7%
Sulfatos	41	4%
Acidez fixa	37	3,6%
Dióxido de enxofre total	33	3,2%
Densidade	30	2,9%
pH	24	2,4%
Dióxido de enxofre livre	16	1,6%
Acidez volátil	10	1%
Teor alcoólico	6	0,6%
Ácido cítrico	1	0,1%

Tabela 3 - Contagem de outliers por variável (método IQR), sobre a base limpa.

Boxplots das variáveis com mais outliers (mantidos na base)




Figura 5 - Boxplots das três variáveis com maior incidência de outliers (mantidos na base).

2.6 Correlações com olhar de negócio

Ressalva: a correlação de Pearson mede associação linear, não causalidade, e não capta relações não lineares — por isso a complementamos adiante com a floresta e o SHAP (Seção 7). A seguir, justifica-se a associação de cada uma das onze variáveis com a nota de qualidade, da mais positiva à mais negativa:

- **Teor alcoólico (+0,486)** — preditor positivo mais forte; teores mais altos acompanham vinhos mais encorpados e maduros, percebidos como de maior qualidade.
- **Sulfatos (+0,258)** — atuam como conservante e antioxidante (estabilidade microbiológica); em níveis adequados preservam aroma e cor, favorecendo a nota.
- **Ácido cítrico (+0,242)** — em pequena quantidade adiciona frescor e vivacidade, contribuindo para o equilíbrio sensorial.
- **Acidez fixa (+0,116)** — correlação positiva fraca; os ácidos não voláteis (sobretudo o tartárico) dão estrutura, mas o efeito isolado sobre a nota é modesto.
- **Açúcar residual (+0,023)** — correlação praticamente nula; em tintos secos varia pouco e quase não distingue qualidade de forma linear, embora possa ter efeito não linear captável pelas árvores.
- **pH (-0,058)** — correlação muito fraca; o pH é consequência da acidez (já representada por outras variáveis), com efeito direto pequeno sobre a nota.
- **Dióxido de enxofre livre (-0,071)** — correlação muito fraca; protege contra a oxidação, mas em excesso gera aroma pungente, de modo que o efeito líquido é quase neutro.
- **Cloretos (-0,122)** — refletem o teor de sal; níveis elevados conferem sabor salgado indesejado, prejudicando a percepção de qualidade.
- **Dióxido de enxofre total (-0,182)** — o excesso sinaliza maior necessidade de conservação e pode produzir aromas e sabores indesejados, associando-se a notas menores.
- **Densidade (-0,185)** — depende do álcool e do açúcar; densidade menor acompanha mais álcool e menos açúcar, combinação ligada a notas mais altas — daí a correlação negativa.
- **Acidez volátil (-0,409)** — preditor negativo mais forte; valores altos (ácido acético) sinalizam deterioração e avinagramento, um defeito sensorial claro.

Correlações entre as variáveis (mapa comentado): como justificar individualmente cada um dos 55 pares seria pouco informativo, destacam-se os blocos com significado químico, que são os que importam para a modelagem. A acidez fixa forma o “esqueleto ácido” do vinho, correlacionando-se com o ácido cítrico (+0,67) e a densidade (+0,67) e, de forma inversa, com o pH (-0,69) — relação esperada, pois mais ácido implica menor pH. O teor alcoólico e a densidade caminham juntos (-0,50), já que o álcool é menos denso que a água. O dióxido de enxofre livre e o total medem o mesmo conservante em frações diferentes (+0,66). Esses agrupamentos antecipam a multicolinearidade tratada na Seção 2.8 (VIF) e mostram por que a correlação linear não capta as interações não lineares exploradas pela floresta e reveladas pelo SHAP (Seção 7).




Figura 6 - Correlação de Pearson de cada variável com a nota de qualidade.




Figura 7 - Mapa de calor das correlações entre todas as variáveis.

2.7 Poder discriminante por classe

Atendendo a uma sugestão de revisão, comparamos a distribuição de cada variável-chave entre as duas classes (corte ≥ 6). O contraste visual confirma os preditores: a classe Alta tem álcool e sulfatos mais altos e acidez volátil e SO_2 total mais baixos — a tradução gráfica do que os modelos exploram.

Distribuição das variáveis-chave por classe (corte ≥ 6)




Figura 8 - Distribuição das variáveis-chave por classe (corte ≥ 6).

2.8 Multicolinearidade (VIF)

O VIF (Variance Inflation Factor) mede o quanto a variância do coeficiente de uma variável é inflada por sua correlação com as demais (regra: > 5 = atenção; > 10 = severo). Aqui, **acidez fixa ($\approx 8,0$) e densidade ($\approx 6,6$)** ultrapassam 5 — coerente com o mapa de calor. Implicação: os coeficientes dessas variáveis na Regressão Logística pedem cautela; o poder preditivo não é prejudicado. As dominantes (álcool, sulfatos, acidez volátil) têm VIF baixo, logo interpretação estável.

Variável	VIF
Acidez fixa	7,97
Densidade	6,62
pH	3,48
Teor alcoólico	3,29
Ácido cítrico	3,24
Dióxido de enxofre total	2,12
Dióxido de enxofre livre	1,89
Acidez volátil	1,77
Açúcar residual	1,71
Cloretos	1,58
Sulfatos	1,47

Tabela 4 - Fator de Inflação de Variância por variável (> 5 = atenção).

3. Pré-Processamento de Dados

3.1 Tratamentos aplicados

O pré-processamento foi desenhado para ser modular, auditável e livre de vazamento de informação (data leakage). Faltantes: a base não tem nulos → nenhuma imputação. Deduplicação: 125 idênticos removidos, Id ignorado → 1.018 amostras. Padronização (média 0, desvio 1) aplicada dentro do pipeline de cada modelo, após o split — garantindo que os parâmetros sejam calculados só no treino. Divisão: 80/20 estratificada → 814 treino / 204 teste.

3.2 Engenharia de variáveis (criada, testada e descartada)

Criamos e testamos a razão SO_2 livre / total (hipótese: fração do conservante ainda ativa). O teste comparou o F1 (validação cruzada) com e sem a variável.

Modelo	F1 sem	F1 com	Δ (com – sem)	Desvio entre dobras
Regressão Logística	0,7603	0,7589	-0,0014	$\pm 0,028$
Random Forest	0,7609	0,7684	0,0076	$\pm 0,021$

Tabela 5 - Efeito da variável so2_ratio no F1 (validação cruzada, 5 dobras).

A variação do F1 é desprezível — menor que o desvio entre dobras (faixa do ruído) — e SO_2 livre e total já estão no modelo individualmente, tornando a razão redundante. Decisão: não incorporar. Resultado academicamente válido: a variável foi criada, testada e descartada com base em evidência.

3.3 Interações entre variáveis

Para demonstrar exploração além do script básico, testamos três interações sugeridas em revisão — álcool×sulfatos, álcool/densidade e acidez volátil×sulfatos — comparando o F1 (CV).

Modelo	F1 sem	F1 com	Δ (com – sem)	Desvio entre dobras
Regressão Logística	0,7603	0,7557	-0,0045	$\pm 0,028$
Random Forest	0,7609	0,7646	0,0037	$\pm 0,021$

Tabela 6 - Efeito das interações no F1 (validação cruzada, 5 dobras).

A variação está dentro do ruído: as árvores já capturam interações implicitamente, e o modelo linear não se beneficia de forma relevante. Decisão: não incorporar.

3.4 Robustez a distribuições assimétricas (teste logarítmico)

Fechando o ponto da Seção 2.4, aplicamos $\log_{10}$ às variáveis assimétricas (açúcar residual, cloretos, SO_2 livre/total, sulfatos) e recomparamos o F1 da Regressão Logística. O ganho é desprezível ($\Delta = 0,0013$, menor que o desvio entre dobras). Conclusão: a assimetria das marginais **não é o gargalo**. O motivo é conceitual — assimetria não é o mesmo que não linearidade: a fraqueza de um modelo linear está em relações não monotônicas, não em marginais tortas; após a padronização (e a regularização L2 escolhida pela busca em grade), a relação monotônica das variáveis dominantes é bem capturada.

Modelo	F1 sem log	F1 com log	Δ	Desvio entre dobras
Regressão Logística	0,7603	0,7615	0,0013	$\pm 0,028$

Tabela 7 - Regressão Logística com e sem transformação logarítmica das variáveis assimétricas.

4. Desenvolvimento de Modelos

4.1 Algoritmos testados experimentalmente

Sete algoritmos foram efetivamente treinados e avaliados sob o mesmo protocolo, cobrindo famílias distintas: Regressão Logística (linear, máxima interpretabilidade); Random Forest (conjunto de árvores, capta não linearidades, robusta a outliers); SVM (fronteira de maior margem); KNN (vizinhos mais próximos); Gradient Boosting (árvores sequenciais, alta precisão); Árvore de Decisão (interpretável, porém instável); e Naive Bayes (probabilístico, rápido). Todos foram encapsulados em pipelines (padronização + estimador), garantindo ausência de vazamento na validação cruzada.

4.2 Tratamento do desbalanceamento (Parte I)

No corte ≥ 7 , os modelos que admitem o recurso receberam `class_weight = 'balanced'`, que penaliza mais os erros na classe minoritária — valorizar cada acerto raro, sem criar dados artificiais. SMOTE e subamostragem foram avaliados e descartados: a base, com 1.018 linhas, é pequena.

4.3 Otimização de hiperparâmetros

Aplicou-se a busca em grade (GridSearchCV, 5 dobras, critério F1) aos dois modelos principais, **sobre o conjunto de treino do corte ≥ 6** . Esclarecimento importante: as **Tabelas 10 a 13 reportam os modelos default** (configuração de fábrica); a busca entrega os modelos otimizados usados na interpretabilidade (Seção 7) e na recomendação final.

O espaço de busca varrido foi: para a Random Forest, número de árvores em {200, 400}, profundidade máxima em {nenhuma, 6, 10} e mínimo de amostras por folha em {1, 2, 5}; para a Regressão Logística, regularização C em {0,01; 0,1; 1; 10} com penalidade L2. A melhor combinação de cada modelo, na tabela a seguir, foi selecionada pelo F1 médio nas cinco dobras.

Modelo	Melhores hiperparâmetros	F1 (validação cruzada)
Regressão Logística	C = 0,1, penalty = l2	0,7564
Random Forest	n_estimators = 400, max_depth = null, min_samples_leaf = 2	0,7696

Tabela 8 - Melhores configurações encontradas pela busca em grade (GridSearchCV).

A Random Forest otimizada obtém F1 de validação cruzada 0,7696 e F1 de teste 0,7733 — leve otimismo da estimativa por validação cruzada, esperado em bases de ~mil amostras, sem superajuste relevante.

Para tornar explícito o ganho da otimização, a tabela abaixo compara o F1 de validação cruzada dos dois modelos principais antes e depois da busca em grade. O ganho é modesto — coerente com o diagnóstico de que o teto vem da sobreposição das classes, não da configuração —, porém positivo e consistente; no teste, a Random Forest otimizada sobe de 0,768 para 0,7733.

Modelo	F1 CV (padrão)	F1 CV (otimizado)	Ganho
Random Forest	0,7623	0,7696	+0,0073
Regressão Logística	0,7547	0,7564	+0,0017

Tabela 9 - Ganho da otimização de hiperparâmetros (F1 em validação cruzada).

5. Avaliação — Parte I (corte ≥ 7 , desbalanceado)

Esta etapa é sobretudo demonstrativa: mostrar, com números reais, por que a acurácia engana em bases desbalanceadas e qual o efeito do ajuste de peso das classes.

A métrica principal de decisão é o F1-Score, média harmônica entre precisão e recall. A escolha é deliberada: a acurácia engana em bases desbalanceadas, como já discutido; a ROC-AUC mede a capacidade de ordenação independentemente do limiar e entra como métrica complementar; o F1, por equilibrar os custos dos dois erros — falsos positivos (prêmio frustrado) e falsos negativos (receita não capturada) —, é o que melhor reflete o objetivo de negócio no ponto de operação. Por isso, é o critério usado para ordenar e selecionar os modelos a seguir.

5.1 Resultados sem correção de desbalanceamento

Vários modelos exibem acurácia alta (SVM 0,897; Regressão Logística 0,887) que apenas reflete a classe majoritária — o **recall** da classe “Alta” é baixíssimo (SVM 0,333: escapam dois em cada três vinhos excelentes). A acurácia de 0,897 mal supera o palpite ingênuo de 0,865. O melhor F1 (Naive Bayes, 0,529) já evidencia a dificuldade. Para a vinícola, subprecificar metade dos melhores lotes é prejuízo mascarado por uma métrica aparentemente boa.

Modelo	Acurácia	Precisão	Recall	F1-Score	ROC-AUC
Naive Bayes	0,843	0,439	0,667	0,529	0,888
Regressão Logística	0,887	0,600	0,444	0,511	0,899
KNN	0,882	0,579	0,407	0,478	0,823
SVM	0,897	0,750	0,333	0,462	0,919
Gradient Boosting	0,858	0,455	0,370	0,408	0,894
Random Forest	0,868	0,500	0,296	0,372	0,899
Árvore de Decisão	0,809	0,313	0,370	0,339	0,623

Tabela 10 - Parte I (corte ≥ 7), sem correção de desbalanceamento. Ordenado por F1-Score.




Figura 9 - F1-Score por modelo na Parte I, sem correção (destaque para o melhor).

5.2 Resultados com ajuste de peso das classes

Com o ajuste, o quadro muda: SVM (F1 0,568) e Regressão Logística (0,539) passam a recuperar a maioria dos vinhos bons (recall 0,926 e 0,889), ao custo de precisão e acurácia — exatamente o trade-off desejado. Ainda assim, o F1 máximo ($\approx 0,57$) confirma que o corte ≥ 7 é intrinsecamente difícil, o que motiva a Parte II.

Modelo	Acurácia	Precisão	Recall	F1-Score	ROC-AUC
SVM	0,814	0,410	0,926	0,568	0,908
Regressão Logística	0,799	0,387	0,889	0,539	0,900
Naive Bayes	0,843	0,439	0,667	0,529	0,888
Árvore de Decisão	0,843	0,432	0,593	0,500	0,737
KNN	0,882	0,579	0,407	0,478	0,823
Gradient Boosting	0,858	0,455	0,370	0,408	0,894
Random Forest	0,882	0,615	0,296	0,400	0,918

Tabela 11 - Parte I (corte ≥ 7), com `class_weight = 'balanced'`. Ordenado por F1-Score.




Figura 10 - F1-Score por modelo na Parte I, com ajuste de peso das classes.

6. Avaliação — Parte II (corte ≥ 6 , equilibrado)

6.1 Comparação entre os modelos

No cenário equilibrado os números tornam-se confiáveis. No teste, Gradient Boosting (0,789), SVM (0,784), Random Forest (0,768) e Regressão Logística (0,758) ficam próximos. Em validação cruzada, a **Random Forest tem o melhor F1 médio** (0,7623) e o menor desvio ($\pm 0,015$) — é a mais robusta e a mais estável entre execuções. A proximidade indica que o teto vem da dificuldade do problema, não do algoritmo (confirmado na Seção 6.4).

Modelo	Acurácia	Precisão	Recall	F1-Score	ROC-AUC
Gradient Boosting	0,765	0,756	0,826	0,789	0,825
SVM	0,765	0,770	0,798	0,784	0,817
Random Forest	0,745	0,748	0,789	0,768	0,803
Regressão Logística	0,730	0,729	0,789	0,758	0,808
KNN	0,716	0,718	0,771	0,743	0,756
Naive Bayes	0,721	0,736	0,743	0,740	0,779
Árvore de Decisão	0,686	0,703	0,716	0,709	0,684

Tabela 12 - Parte II (corte ≥ 6): desempenho no conjunto de teste. Ordenado por F1-Score.




Figura 11- F1-Score por modelo na Parte II (conjunto de teste).

Modelo	F1 médio (validação cruzada)	Desvio-padrão
Random Forest	0,7623	± 0,015
Gradient Boosting	0,7555	± 0,017
Regressão Logística	0,7547	± 0,021
Naive Bayes	0,7502	± 0,020
SVM	0,7488	± 0,021
KNN	0,7220	± 0,029
Árvore de Decisão	0,6882	± 0,020

Tabela 13 - Estabilidade dos modelos: F1 médio e desvio em validação cruzada (5 dobras).

6.2 O trade-off entre os dois erros e o impacto no negócio

Falso positivo — prever “Alta” para um vinho comum → produto premium aquém da expectativa, risco de devolução e dano à marca; pede maior precisão (SVM 0,770; Gradient Boosting 0,756). **Falso negativo** — prever “Baixa/Média” para um vinho excelente → perda direta de receita; pede maior recall (Gradient Boosting 0,826). A matriz de confusão contrasta o modelo recomendado (Random Forest otimizada) com o líder de F1 no teste (Gradient Boosting).




Figura 12 - Matrizes de confusão no conjunto de teste (corte ≥ 6): recomendado × melhor F1.

6.3 Capacidade de separação (curva ROC)

A maior área sob a curva ROC é do Gradient Boosting (0,825), seguido por SVM (0,817), Regressão Logística (0,808) e Random Forest (0,803). Todos separam bem as classes ($AUC \approx 0,80$), mesmo que o limiar-padrão não seja ideal para todos os cenários de negócio.




Figura 13 - Curvas ROC dos sete modelos (corte ≥ 6), com as respectivas áreas (AUC).

6.4 Significância estatística e robustez das diferenças

Para responder “as diferenças entre os melhores modelos são reais?”, aplicamos quatro instrumentos:

1. **McNemar** (acertos/erros pareados no teste): Gradient Boosting $\times$ SVM $p = 1,00$; Gradient Boosting $\times$ Random Forest $p \approx 0,54$; Regressão Logística $\times$ Random Forest $p \approx 0,73$ — nenhuma diferença significativa.
2. **Comparação pareada por dobras** (Random Forest $\times$ Regressão Logística): diferença média 0,0076, $p \approx 0,55$.
3. **Bootstrap (IC 95%) do F1 no teste**: os intervalos se sobrepõem amplamente (ver Tabela 14).
4. **Curva Precision-Recall (Figura 14)**: a Regressão Logística tem a maior Average Precision (0,833), com Gradient Boosting (0,831) e SVM (0,824) logo atrás.

Modelo	F1 (teste)	IC 95% (bootstrap)
Regressão Logística	0,758	[0,691 ; 0,816]
Random Forest	0,768	[0,704 ; 0,828]
Gradient Boosting	0,789	[0,726 ; 0,845]
SVM	0,784	[0,718 ; 0,841]

Tabela 14 - F1 de teste e intervalo de confiança de 95% (bootstrap, 3.000 reamostragens).

Curvas Precision-Recall — Parte II (corte ≥ 6)




Figura 14 - Curvas Precision-Recall (corte ≥ 6), com Average Precision (AP).

Conclusão: no topo, os modelos são estatisticamente indistinguíveis. A escolha do modelo de produção deve ser feita por critérios operacionais (estabilidade, robustez, interpretabilidade), não pelo F1 de uma única partição. Isso responde diretamente à pergunta “se um modelo teve o melhor F1, por que não é o principal?”: a vantagem não é estatisticamente real.

Uma pergunta natural: se o Gradient Boosting obteve o melhor F1 no conjunto de teste (0,789), por que recomendar a Random Forest (0,768)? Porque o F1 de uma única partição de teste, com apenas 204 amostras, é uma estimativa ruidosa. Os testes de McNemar e pareado mostram que as diferenças no topo do ranking não são estatisticamente significativas; e na validação cruzada — mais robusta, por reaproveitar cinco partições — a Random Forest tem o melhor F1 médio (0,7623) e a menor variância ($\pm 0,015$), enquanto o Gradient Boosting recua para 0,7555 e o SVM, segundo melhor no teste (0,784), cai para 0,7488. A recomendação prioriza, portanto, o desempenho estável e reprodutível sobre o pico de uma única amostra.

7. Interpretação dos Resultados

Entender por que o modelo decide é tão importante quanto saber o quanto ele acerta — é o que transforma um classificador em ferramenta de gestão. Três métodos independentes foram empregados; sua convergência reforça a confiança. A análise usa a Random Forest com os melhores hiperparâmetros, sem padronização (árvores são invariantes à escala).

7.1 Importância das variáveis pela Random Forest

O primeiro método mede a contribuição média de cada variável. A ordem: teor alcoólico (0,204), sulfatos (0,135), acidez volátil (0,117), dióxido de enxofre total (0,098), entre as principais. As de menor contribuição (açúcar residual, SO_2 livre) merecem nota: o açúcar residual é também o de mais outliers (9,3%), o que pode diluir seu poder; já o SO_2 livre tem poucos outliers (1,6%), então sua baixa importância não se explica por outliers.




Tabela 15 - Importância das variáveis segundo a Random Forest.

7.2 Análise SHAP

O SHAP (teoria dos jogos cooperativos) decompõe cada previsão nas contribuições de cada variável, revelando importância, direção e intensidade. A leitura confirma a correlação: teor alcoólico alto empurra fortemente para “alta qualidade”; acidez volátil alta empurra para “baixa qualidade”; sulfatos elevados têm efeito positivo. O SHAP também revela não linearidades — por exemplo, teores alcoólicos muito baixos têm efeito fortemente negativo, sugerindo uma faixa ótima.





Tabela 16 - Resumo SHAP: impacto de cada variável na previsão da classe “Alta qualidade”.

Mais do que confirmar a correlação, o SHAP revela não linearidades que uma leitura linear não captaria. No teor alcoólico, o impacto é fortemente negativo abaixo de ~10%, cresce de forma acentuada entre 10% e 12% e atinge o ponto de maior contribuição em torno de 12–12,5%, com leve acomodação nos teores mais altos — o que sustenta a faixa favorável de 11% a 13%. Nos sulfatos, o achado é mais instrutivo: o efeito positivo cresce até cerca de 0,7–0,85 g/L e então satura; acima desse patamar, dosagens maiores não aumentam a contribuição para a classe de alta qualidade (e chegam a recuar levemente). Isso contradiz a leitura ingênua da correlação positiva (+0,258), que sugeriria 'quanto mais, melhor': há um ponto de retorno decrescente, com implicação direta de processo — ajustar os sulfatos a uma faixa intermediária, sem excesso.

7.3 Implicações para o processo produtivo

- Monitorar o teor alcoólico como indicador de maturação: vinhos com teor abaixo de ~10% tendem a baixa/média qualidade; a faixa mais favorável situa-se entre 11% e 13%.
- Controlar rigorosamente a acidez volátil, mantendo-a baixa, com higienização de equipamentos e monitoramento microbiológico da fermentação.
- Ajustar os sulfatos a uma faixa intermediária, em que o efeito positivo é maximizado, evitando falta e excesso.

Atentar à qualidade da água de processo: cloretos elevados prejudicam de forma consistente a classificação.

Tabela 17 - Dependência SHAP do teor alcoólico e dos sulfatos (corte ≥ 6).

7.4 Importância por permutação

O terceiro método mede a queda no F1 ao embaralhar cada variável, destruindo sua relação com o alvo; independe do tipo de modelo. O ponto-chave é a convergência: os três métodos — importância da floresta, SHAP e permutação — apontam o mesmo trio (teor alcoólico, sulfatos e acidez volátil), tornando o resultado robusto. O gráfico foi revisado para exibir rótulos com sinal, sem colisão.




Tabela 18 - Importância por permutação (queda média de F1), gráfico revisado.

8. Riscos, Limitações e Governança

Em coerência com o princípio de antecipar o que pode dar errado, os principais riscos foram mapeados com suas mitigações.

- Superajuste da Random Forest — mitigado por GridSearchCV com validação cruzada, controlando profundidade e tamanho mínimo das folhas.
- Viés da avaliação sensorial — o alvo deriva de julgamentos humanos; mitigação plena exigiria medir a concordância entre degustadores.
- Degradação com novos lotes — base estática, sem marcação temporal; recomenda-se monitoramento periódico.

8.1 Limitações metodológicas

- Tamanho da base (~1.018): estimativas menos precisas (note os intervalos de confiança largos na Tabela 14) — revalidar com dados novos antes de implantar.
- Correlação não é causalidade: as interpretações de mecanismo são hipóteses, a confirmar com enólogos.
- Ausência de marcação temporal: impede avaliar a degradação ao longo do tempo.
- Escopo restrito a vinhos tintos: não aplicar a brancos/espumantes sem novo treinamento.

8.2 Reprodutibilidade

Todo o trabalho é reproduzível. A mesma semente aleatória (**SEED = 43**, número primo adotado por decisão de grupo) é usada na divisão dos dados, na inicialização dos modelos e na validação cruzada. As dependências estão registradas e o notebook que acompanha o projeto foi executado de ponta a ponta, sem erros, antes da entrega.

9. Conclusões e Recomendações

O projeto demonstrou ser viável classificar a qualidade de vinhos tintos, com F1-Score de 0,76 a 0,79 no teste (0,75 a 0,77 em validação cruzada), utilizando apenas variáveis físico-químicas mensuráveis na linha de produção. Os principais aprendizados:

- A escolha do ponto de corte é uma decisão de pré-processamento determinante: o corte ≥ 7 gera desbalanceamento severo que limita o desempenho mesmo com correção de peso, enquanto o corte ≥ 6 reduz substancialmente o desbalanceamento na origem e é a estratégia recomendada.
- No cenário equilibrado os sete algoritmos convergem para um patamar semelhante; os testes estatísticos (Seção 6.4) mostram que as diferenças no topo não são significativas. A Random Forest destaca-se por ser a mais robusta e estável em validação cruzada.
- Três variáveis dominam — teor alcoólico (+), sulfatos (+) e acidez volátil (–) — confirmadas por três métodos independentes, com mecanismos produtivos claros e monitoráveis.
- As variáveis engenheiradas (razão SO_2 livre/total e interações) foram criadas, testadas e descartadas por não agregarem valor preditivo — resultado legítimo e documentado.
- A otimização de hiperparâmetros trouxe ganho modesto, sinalizando que o gargalo está na sobreposição natural entre as classes, não na configuração dos modelos.

10. Recomendação de implantação

Como os melhores modelos são estatisticamente equivalentes, a escolha é feita por critérios operacionais. Recomenda-se adotar a **Random Forest otimizada** ($n_estimators = 400$, $max_depth = \text{null}$, $min_samples_leaf = 2$) como modelo de produção — melhor e mais estável desempenho em validação cruzada, robusta aos outliers mantidos e interpretável (Seção 7). Manter a Regressão Logística como modelo-companheiro transparente (coeficientes auditáveis, maior average precision), útil quando a decisão precisa ser explicada de forma linear. O Gradient Boosting lidera o F1 numa única partição, mas a vantagem não é estatisticamente significativa. Recomenda-se monitorar o F1 periodicamente sobre novos lotes.

Traduzindo em valor de negócio: ao operar como uma triagem automatizada e padronizada, o modelo recomendado reduz a dependência da degustação manual — mais lenta e custosa — e acelera a separação dos lotes. O equilíbrio entre os dois erros tem efeito financeiro direto: cada falso negativo é um lote de alta qualidade subprecificado (receita não capturada) e cada falso positivo é um prêmio frustrado (risco de devolução e de imagem). A escolha da Random Forest apoia-se em sua estabilidade e no equilíbrio entre os dois erros, oferecendo desempenho previsível em produção; e o limiar de decisão pode ser calibrado conforme a prioridade da vinícola — favorecer o recall, para não perder lotes bons, ou a precisão, para proteger o prêmio —, protegendo a margem apontada na Seção 1.1. Recomenda-se acompanhar, além do F1, indicadores de negócio — acerto na faixa premium e receita incremental dos lotes reclassificados — para confirmar, em produção, o retorno esperado.

11. Referências

CORTEZ, P.; CERDEIRA, A.; ALMEIDA, F.; MATOS, T.; REIS, J. Modeling wine preferences by data mining from physicochemical properties. *Decision Support Systems*, v. 47, n. 4, p. 547-553, 2009. DOI: 10.1016/j.dss.2009.05.016.

KAGGLE. Wine Quality Dataset (WineQT). Disponível em: <https://www.kaggle.com/datasets/yasserh/wine-quality-dataset>. Acesso em: 19 jun. 2026.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825-2830, 2011.

LUNDBERG, S. M.; LEE, S.-I. A Unified Approach to Interpreting Model Predictions. In: *Advances in Neural Information Processing Systems (NeurIPS 30)*, 2017. Disponível em: <https://arxiv.org/abs/1705.07874>.

BREIMAN, L. Random Forests. *Machine Learning*, v. 45, n. 1, p. 5-32, 2001. DOI: 10.1023/A:1010933404324.

McKINNEY, W. Data Structures for Statistical Computing in Python. In: *Proceedings of the 9th Python in Science Conference (SciPy 2010)*, p. 56-61, 2010. DOI: 10.25080/Majora-92bf1922-00a.

HARRIS, C. R. et al. Array programming with NumPy. *Nature*, v. 585, p. 357-362, 2020. DOI: 10.1038/s41586-020-2649-2.

Vídeo do Youtube: <https://youtu.be/24i8LucBWxU?si=hbToJGP8F1KqrZIN>

Repositório GITHUB: <https://github.com/lgmricardo/Techchallenge2-G12>